

ADATSZERKEZETEK

Mintaillesztés

MINTAILLESZTÉS

- Adott egy karakterlánc
- elemek Σ - ábécéből

s karakterlánc — T minta

- Hol fordul elő s-ben a T?


$S - n$ kar.

$m \leq n$

$T - m$ kar

① Egyetemes műtálások (brute force)

$S: ABABABC$ $T: AB$



illetességedik

$T[1..m] = S[i+1..i+m]$

eltolás

$S[i+1, \dots, i+m]$

i eltolás +


alkalmaz

drágyses eltolás

eltol + illeszkedik

- próbálkozások száma: n
- illeszkedés ellenőrzése: m

$$\boxed{O((n-m+1)m)}$$



$s[i+1] \sim 'A'$

$\overbrace{1, \text{jos}}$ helyen A van

- műs eljel dolgoz
- nem használ fel ismertetés

for $i = 0 \rightarrow n-m+1$

Elrendezés

$$T[1, \dots, m] = S[i+1, i+2, \dots, i+m]$$

"vagy illeszkedik"

"vagy az előző elrendezéshez kötődik"

ellenőrzeszt

Ha illeszkedik \rightarrow kik T^{0,2}.

Minta : belső⁴ szerekezett

S : $\overset{1.}{A}, \overset{2.}{B}, \overset{3.}{AB}, ABC$

$A+B$

\rightarrow nem lesz megfelelő⁴

$+1$ $\rightarrow AB$


T : ABC

- vizsgáljuk a lehetséges eltolásokat
- csak addig hajtjuk végre az illesztést, míg teljesülnek bizonyos alapfeltételek.

② Rabin - Karp algorithmus

$S, T \in \Sigma^*$ a b c e

legyen $d = |\Sigma| \Rightarrow S \in T$ egg - egg



~~R~~ Rabin - Karp algoritmus

T mint sátor egysége

$S[i+1, \dots, i+n]$, számlál?

Példa

$$S: 12537986258$$

$$T: 25$$

Legyen $s_i = S[i+1, \dots, i+m]$ // mint szám
 $t = T[1, \dots, m]$ // mint szám

$s_0, s_1, s_2, \dots, s_{n-m+1}$ közül ki egyszerű t-sel

$$s_0 = d^{m-1} s[1] + d^{m-2} s[2] + d^{m-3} s[3] + \dots + s[m]$$

(Horner-széma) $= s[m] + d(s[m-1] + d(s[m-2] + \dots + d(s[0]) \dots))$


Pílda

$$S: \boxed{125} 37986258 \quad T: 25 \nmid 7$$

$$(25) \quad S_0 = 10^1 \cdot 1 + 10^0 \cdot 2 = 12$$

$$(258) \quad S_0 = 10^2 \cdot 1 + 10^1 \cdot 2 + 10^0 \cdot 5 = 125 \quad (\Theta(n))$$

$$S_0 \rightarrow S_1 \quad \Theta(1)$$



$$S_1 = d(S_0 - d^{m-1} \cdot S[1]) + S[m+1]$$

$$\left\{ \begin{array}{l} S_i = d(S_{i-1} - d^{m-1} \cdot S[i+1]) + S[i+1] \end{array} \right.$$

Elo'nyo': illesztés konstans 'do': $s_i \stackrel{?}{=} t$

Hátrány: nagy számos.

Megoldás: maradványtól

leggén \boxed{q} felszöges szám

$$s_i \bmod q \equiv t \bmod q$$

$$s_i \equiv t \pmod{q}$$

$$s_i = d \left(s_{i-1} - \underbrace{d^{m-1}}_1 [s[i]] \right) + s[i+m]$$

m számjegyű szám

d számrendszerben

$$s_i = d \left(s_{i-1} - \underbrace{d^{m-1}}_1 [s[i]] \right) + s[i+m] \pmod{2}$$

$$h \equiv d^{m-1} \pmod{2}$$

$$\boxed{s_i = d \left(s_{i-1} - h [s[i]] \right) + s[i+m] \pmod{2}}$$

Melle'lé hatás:

$$s_i \equiv t \Rightarrow s_i \equiv t \pmod{q}$$

- ha egységes faktoruk $\not\equiv$ \Rightarrow teljes illesztés.
ellenőrzés

[Ötlet]: Két q -val (q_1, q_2) párosításban szerepel
 $\text{lcm}(q_1, q_2) = 1$.


Konkavitets — való feladatnál aránylag kicsi
 a konvex felállat lehetsége
 — L — réteg el magyobb mint s hossza
 \Rightarrow konvex függvény felállat

- Legrosszabb eset: $O((n - m + 1)m)$
- Átlagos eset: $O(n) + O\left(m\left(n + \frac{n}{2}\right)\right)$ n -as soroknak eltolásuk szükséges

③ KMP (Knuth - Morris - Pratt) algoritmus

- bilső szákeretet nincs: a minta összetétele

S: ababc T: abc



Alg: előfeldolgozás

Határozunk meg ezzel [Prefix függvény]

Prefix függvény: $q = \overline{1, m}$ határozunk meg

P_q ($P_q = P[1 \dots q]$) begörsszéssel

valódi prefixt, ami szájban

"valódi" prefix: pl. ABC Valódi Prefixei: A, AB

	A	C	A	B	A	C	A	C
Q	1	2	3	4	5	6	7	8
PF	0	0	1	0	1	2	3	2

Prefix: fijgq meny

$$q=2$$

VP: A

S₈: Σ

AC

$$q=3$$

VP: A, AC

S₇: A, CA

AC A

$$q=4$$

VP: A, AC, ACA

S₆: B, AB, CBA

ACAB

$$q=5$$

VP: A, AC, ACA
ACB

S₅: A, BA, ABA,
CABA


CAB A

$$q=6$$

VP: A, AC, ACA
ACB, ACBA

S₄: C, AC, BAC,
ABA, CABAC

ABA CABAC



Lehenslösungen

$$S[i] =$$

neu erzeugte $P[q]$ -ral

$$q = PR_{Q-1} + 1$$

zur Anfangsliste

an PR_{Q_1} O fest \rightarrow letzter
 $i-t$

$S[i] = P[q] \rightarrow$ da $q = n$ oder k

a b b a b a b
a b c

a x
a x
a x
a x
a x
a x

a ya
o.

$$q = PR_{Q-1} + 1$$

list

Feltárolásido⁴:

előfeloldás: $O(m)$ (amortizált)

illesztés:


: $\overbrace{O(n)}^{O(m+n)}$ ↗

$$m \ll n$$

$$\overbrace{O(n)}^{O(m+n)}$$

④ Boyer - Moore algoritmus


- ngrással megoldja az ablakot (minták)
- haladás: itály
illesztés: itály



a) Rossz karakter levezetésre $s[i+u] = x$
ha $p[m] \neq x$

akkor az alkalmazott eljárás $e_1 = x$ utolsó előfordulása a mintában

b.) \exists^1 szájfix heurizálás



amit modelje kér, hogy az utolsó
 \exists^1 szájfix a helyére kerüljön.
eg elholás

Telj leges elbals: $\max(e_1, e_2)$

Futasi ido⁴

$$O(|\Sigma| + m)$$

előfeldolgozás

$$O((n - m + 1)m + |\Sigma|)$$

legrosszabb
eset

